

GVHD: TS. Dương Việt Hằng

Mục lục

- 1 Tổng quan đề tài
- 2 Phương pháp thực hiện
- 3 Thực nghiệm và kết quả
- 4 Demo và đánh giá hệ thống
- 5 Kết luận và hướng phát triển

Mục lục

- 1 Tổng quan đề tài
- 2 Phương pháp thực hiện
- 3 Thực nghiệm và kết quả
- 4 Demo và đánh giá hệ thống
- 5 Kết luận và hướng phát triển

1.1. Mô tả bài toán

Định nghĩa

Object Counting – ước lượng số lượng đối tượng thuộc một lớp cho trước trong ảnh tự nhiên.
Zero-shot Counting – chỉ cần ảnh + text prompt (tên lớp), *không cần mẫu hình ảnh thủ công*.
Hệ thống tự động sinh mẫu (exemplar) và tạo bản đồ mật độ (density map) để đếm.

Ví dụ

Ảnh chứa nhiều quả cam + prompt "oranges" $\Rightarrow$ hệ thống trả về density map + tổng số cam.

Ứng dụng

- Nông nghiệp thông minh (đếm quả, cây trồng).
- Giám sát giao thông, kiểm kê kho hàng.
- Phân tích hình ảnh y tế, phân tích đám đông.

Thách thức

- Biến thiên lớn về mật độ và kích thước đối tượng.
- Đối tượng nhỏ, sát nhau $\Rightarrow$ khó tách ranh giới.
- Nền phức tạp, đối tượng tương tự $\Rightarrow$ nhầm lẫn tiền cảnh/nền.

1.2. Lý do chọn đề tài

Bối cảnh

- Nhu cầu tự động hóa phân tích hình ảnh ngày càng lớn.
- Các phương pháp hiện tại: phụ thuộc nhãn thủ công, hạn chế miền đối tượng, tính thủ công của few-shot.

Tiếp cận	Mô tả	Hạn chế
Class-specific	Chỉ đếm lớp đã huấn luyện	Không mở rộng được sang lớp mới
Few-shot	Cần vài mẫu hình ảnh từ người dùng	Thủ công, không tự động hóa
Zero-shot	Chỉ cần text prompt	Thách thức về chất lượng mẫu tự sinh

Mục tiêu đề án

- **Tự động hóa** quy trình lấy mẫu: loại bỏ can thiệp thủ công.
- **Xây dựng** tương tác đa phương thức (text prompt ↔ đặc trưng ảnh).
- **Tối ưu hóa** khả năng tổng quát hóa trên lớp đối tượng mới.

1.3. Phát biểu bài toán

Input


- Ảnh màu RGB $I \in \mathbb{R}^{H \times W \times 3}$.
- Text prompt T – tên lớp tiếng Anh (ví dụ: "oranges", "keyboard keys").
- Bộ dữ liệu chuẩn FSC-147 (6 135 ảnh, 147 lớp).

Output

- Bản đồ mật độ (density map) $D \in \mathbb{R}^{H \times W}$.
- Tổng số lượng đối tượng $\hat{y} = \int_{H,W} D \, dx \, dy$.

Ràng buộc

- **Dữ liệu ảnh:** ảnh RGB, mật độ rất biến thiên; mỗi lần thực thi chỉ đếm *một lớp* đối tượng.
- **Câu lệnh:** bằng tiếng Anh; mô tả vật thể hữu hình quan sát được; không sử dụng khái niệm trừu tượng (traffic, meeting) hay danh từ không đếm được (water, smoke).




1.4. Lý do chọn VA-Count làm baseline

Ba lý do chính

- 1 **Cơ chế tự sinh mẫu (exemplar) hoàn toàn tự động.**
Dùng GroundingDINO phát hiện sơ bộ $\Rightarrow$ không cần bounding box thủ công.
- 2 **Kiến trúc hai nhánh đối lập (contrastive dual-branch).**
Nhánh dương + nhánh âm $\Rightarrow$ phân biệt tiền cảnh/nền hiệu quả.
- 3 **Thiết kế module hóa, dễ mở rộng.**
Tách biệt EEM (lấy mẫu) và NSM (sinh density map) $\Rightarrow$ thay thế từng thành phần dễ dàng.

VA-COUNT: Zero-Shot Object Counting Visualization

Ảnh gốc
Positive (xanh lá) & Negative (đỏ) Exemplars



Overlay: Image + Prediction



[[KIT (K) SO SÁNH

Image ID:
346.jpg

Groundtruth Count: 11


Predicted Count: 14.18

Absolute Error: 3.18

Error Percentage: 28.21%

Hình 1: Minh họa VA-Count: positive exemplars (xanh lá) và negative exemplars (đỏ).

2.1. Kiến trúc tổng quan VA-Count



Hình 2: Tổng quan kiến trúc VA-Count: hai nhánh positive/negative qua EEM và NSM.

Hai nhánh xử lý

- **Nhánh dương:** tìm mẫu dương $\Rightarrow$ density map D_p tập trung vào đối tượng cần đếm.
- **Nhánh âm:** tìm mẫu âm $\Rightarrow$ density map D_n tập trung vào nhiễu nền.

Hai module chính

- 1 **EEM (Exemplar Enhancement Module):** tự động phát hiện & tinh chỉnh mẫu.
- 2 **NSM (Noise Suppression Module & Counter):** sinh density map + khử nhiễu.

2.1. Noise Suppression Module & Counter – NSM (tt.)

Mục tiêu

Tối đa hóa sự tương đồng $D_p \leftrightarrow D_g$, giảm thiểu $D_n \leftrightarrow D_g$. Nhờ vậy, NSM giúp hệ thống học được “cái gì là đối tượng” và “cái gì không phải là đối tượng”.

Pha 1: Tương tác đặc trưng & sinh density map

Counter gồm: *Image Encoder*, *Interaction Module*, *Decoder*.

- Feature ảnh = *Query*.
- Phép chiếu tuyến tính feature mẫu (E_p, E_n) = *Key/Value*.
- Attention + Decoder $\Rightarrow$ hai bản đồ mật độ:

$$D_p = \Gamma_{\text{decode}}(F_{\text{fuse}}^p), \quad D_n = \Gamma_{\text{decode}}(F_{\text{fuse}}^n)$$

Pha 2: Hàm mất mát (Loss)

Dạng *margin-ReLU* contrastive (ổn định số học hơn dạng softmax gốc):

$$\mathcal{L}_{\text{pos}} = \frac{1}{HW} \sum_{i,j} M_{ij} (D_p^{(i,j)} - D_g^{(i,j)})^2$$

$$\mathcal{L}_{\text{neg}} = \frac{1}{HW} \sum_{i,j} M_{ij} (D_n^{(i,j)} - D_g^{(i,j)})^2$$

$$\mathcal{L}_C = \text{ReLU}(\mathcal{L}_{\text{pos}} - \mathcal{L}_{\text{neg}} + m)$$

$$\mathcal{L}_{\text{total}} = \mathcal{L}_C + \mathcal{L}_{\text{pos}}$$

$m = 0.5$; M : Bernoulli mask ($p = 0.8$) áp lên mỗi pixel.

Ý nghĩa

$\mathcal{L}_C$ ép D_p luôn gần D_g hơn D_n ít nhất margin m . $\mathcal{L}_{\text{pos}}$ đảm bảo bản đồ mật độ dương khớp ground truth. Kết hợp cả hai: hệ thống vừa đếm đúng vừa loại nhiễu.


2.2. Cải tiến với Rich Prompts

Động lực

- Tên lớp đơn giản $\Rightarrow$ nhập nhầm ngữ nghĩa ("key" = phím / chìa khóa?).
- Thiếu thông tin phân biệt tiền cảnh/nền khi nền phức tạp.

Giải pháp: Gemini 2.0 Flash

- **Positive Prompt:** mô tả đặc trưng thị giác cốt lõi (shape, color, material).
- **Negative Prompt:** mô tả nền, vật thể gây nhiễu.
- **CLIP ViT-L/14 Re-ranking:** lọc ngữ nghĩa cấp hai, đảm bảo patch khớp tên lớp gốc.
- Top-3 $\rightarrow$ **Top-5** mẫu dương.



Hình 3: Pipeline Enhanced Prompt: Image + ClassName $\rightarrow$ Gemini $\rightarrow$ enhanced prompts.



Hình 4: Ví dụ: top-3 positive boxes cho keyboard keys sau CLIP re-rank.

2.2. Cải tiến với Rich Prompts – Mẫu Prompt (tt.)

Chi tiết các prompt mẫu được thiết kế để định hướng mô hình tập trung vào đặc trưng thị giác cốt lõi:

Listing 1: Positive Prompt

```
Look at the image and provide the
visual definition of a single
'{singular_name}'.

Task: Describe the intrinsic physical
appearance of just ONE instance, as if
it were isolated.

STRICT RULES:
1. Subject: Describe ONE item only.
   Ignore background or other items.
2. Format: Start with
   'single {singular_name}'.
   Use dot-separated phrases.
3. Content: Focus on Shape, Color,
   Material.

Example for 'keyboard key':
BAD:  keyboard key . rows of buttons .
GOOD: single keyboard key .
      square shape . black plastic .

Your output for '{singular_name}':
```

Listing 2: Negative Prompt

```
Analyze the image and identify visual
elements that are NOT '{class_name}'.

Describe background, environment, and
potential distractors.


Focus strictly on:
1. Background materials.
2. Environmental conditions.
3. Other objects that are NOT
   '{class_name}'.

Output format rules:
- Do NOT describe '{class_name}'.
- Separate phrases with ' . '.
- Do NOT write full sentences.
- End with a dot.

Example input: Image of a cat on sofa.
Example output: beige sofa texture .
               blurry living room . shadows .
               fabric patterns .

Your output for this image:
```

2.2. Cải tiến với Rich Prompts – Kiến trúc (tt.)



Hình 5: Kiến trúc sau tích hợp Rich Prompt: Gemini sinh prompt → GroundingDINO → CLIP ViT-L/14 re-rank → NSM.

Ngày 3 tháng 5 năm 2026 16 / 40


2.3. Cải tiến với YOLO-World

Vấn đề: GroundingDINO là bottleneck

- Chiếm ~80% thời gian xử lý mỗi ảnh.
- 6 146 ảnh FSC-147: ≈ 13 giờ (baseline), 25 giờ (+Rich Prompt).
- Demo: $\sim 1,5$ s/ảnh chỉ cho bước phát hiện.


YOLO-World: Prompt-then-Detect

- Mã hóa **ngoại tuyến** text prompt thành tham số mô hình.
- Suy luận **không cần** gọi lại bộ mã hóa ngôn ngữ.
- **RepPAN**: đóng gói thông tin ngôn ngữ vào tham số mạng cố định.
- Nhanh hơn GroundingDINO $\sim 20\times$ (50–80 FPS vs < 5 FPS).



Hình 6: Speed-Accuracy: YOLO-World vs GroundingDINO/GLIP trên LVIS minimal.

2.3. Cải tiến với YOLO-World (tt.)



Hình 7: Kiến trúc VA-Count với YOLO-World thay GroundingDINO.

Mục lục

- 1 Tổng quan đề tài
- 2 Phương pháp thực hiện
- 3 Thực nghiệm và kết quả
- 4 Demo và đánh giá hệ thống
- 5 Kết luận và hướng phát triển


3.1. Bộ dữ liệu FSC-147

Thông tin FSC-147

- 6 135 ảnh, 147 lớp đối tượng.
- Chú thích điểm (dot annotation).
- Chia 6:2:2 (train:val:test) không chồng lấn theo lớp.
- Biến thiên lớn: mật độ, kích thước, bối cảnh.
- Nhãn lớp + dot annotation cho phép đánh giá zero-shot thông qua text prompt.



Hình 8: Một số ảnh minh họa từ FSC-147.



Hình 9: Kết quả tốt: 4910 .jpg (chocolates), GT=14, Pred=14.40.

3.2. Độ đo đánh giá

Hệ thống được đánh giá bằng hai độ đo (metric) chuẩn cho bài toán đếm:

Mean Absolute Error (MAE)

Đo trung bình giá trị sai số tuyệt đối:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

N : số ảnh, y_i : ground truth, $\hat{y}_i$: dự đoán.

⇒ Phản ánh **độ chính xác trung bình**.

Root Mean Squared Error (RMSE)

Phạt nặng các sai số lớn nhờ bình phương trước khi lấy căn:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

⇒ Phản ánh **độ ổn định** trên các trường hợp khó (outlier).

Nhận xét

Sử dụng đồng thời cả hai cho phép đánh giá toàn diện: MAE phản ánh độ chính xác trung bình; RMSE phản ánh độ ổn định trên các trường hợp khó.

3.3. Thiết lập thực nghiệm

Cấu hình phần cứng

- **Huấn luyện:** NVIDIA H200, 24 CPU, 192 GB RAM.
- **Demo:** Intel i7-13620H + RTX 4060.

Siêu tham số

Tham số	Giá trị
Optimizer	AdamW
Learning Rate	1×10^{-5}
Weight Decay	0.05
LR Schedule	Cosine
Epochs	500
Batch size	8
Grad Accum	16 steps

3.4. Kết quả thực nghiệm

Hiệu suất đếm trên dataset FSC-147

Mô hình	MAE ↓	RMSE ↓
VA-Count (Baseline)	17,99	129,39
VA-Count + Rich Prompt	17,80	129,69
VA-Count + YOLO-World	19,03	131,55
VA-Count + YOLO-World + Rich Prompt	17,91	130,98

Phân tích

- MAE khoảng hẹp 17,80–19,03 $\Rightarrow$ chất lượng bị giới hạn bởi Counter (MAE-based).
- Rich Prompt trên GDino: $\Delta = 0,19$ (gần bão hòa ngữ nghĩa).
- Rich Prompt trên YOLO: $\Delta = 1,12$ (lợi ích lớn).

Hiện tượng bão hòa ngữ nghĩa

- GroundingDINO đã khai thác gần hết thông tin text $\Rightarrow$ thêm chi tiết ít lợi ích.
- YOLO-World yếu hơn về ngữ nghĩa $\Rightarrow$ Rich Prompt bù đắp hiệu quả.
- *Bộ phát hiện càng yếu, Rich Prompt càng có ích.*

3.4. Thời gian trích xuất mẫu


Phương pháp	Positive (giờ)	Negative (giờ)
Grounding DINO (Baseline)	≈ 3	≈ 10
Grounding DINO + Rich Prompt	≈ 10	≈ 15
YOLO-World	≈ 0.5	≈ 2
YOLO-World + Rich Prompt	≈ 1	≈ 3

Nhận xét

- YOLO-World nhanh gấp **6×** GroundingDINO (positive).
- GroundingDINO + Rich Prompt: **25 giờ** tổng vs YOLO-World + RP: **4 giờ**.
- Khác biệt mang tính quyết định cho chuẩn bị dữ liệu quy mô lớn.

3.4. Minh họa kết quả đếm đúng


Hệ thống cho thấy khả năng đếm chính xác cao trên nhiều loại đối tượng đa dạng. Dưới đây là ba ví dụ tiêu biểu trên tập test:



Hình 10: Táo: GT= 33, Pred= 32,67.
Sai số 1%.



Hình 11: Cừu: GT= 32, Pred= 32,2.
Sai số 0,6%.



Hình 12: Bi: GT= 11, Pred= 11,2.
Sai số 1,8%.

Nhận xét


Bên trái: ảnh gốc với positive exemplars (xanh lá) và negative exemplars (đỏ). Bên phải: density map với overlay dự đoán. Bản đồ mật độ tập trung chính xác vào vị trí các đối tượng, cho sai số < 2% trên các trường hợp này.

3.4. Tốc độ suy luận & đánh đổi tốc độ–chính xác

Phương pháp	s/ảnh
VA-Count	1,47
VA-Count + RP	5,76
YOLO-World	0,60
YOLO + RP	2,41


Nhận xét

- YOLO-World: **0,60s** ($2,5\times$ nhanh hơn baseline).
- YOLO + RP**: MAE 17,91 với 2,4s/ảnh $\Rightarrow$ cân bằng tốt nhất.



Đánh đổi tốc độ – chính xác. Mũi tên: hướng tối ưu.


3.4. Phân tích MAE theo mật độ đối tượng



Nhận xét

- Mật độ thấp (<50 obj/Mpx): MAE < 10 ở mọi cấu hình.
- Mật độ cao (>500 obj/Mpx): MAE vượt 50 $\Rightarrow$ đếm thiếu ở mật độ dày đặc.
- YOLO-World (không RP) luôn có MAE cao nhất ở mọi nhóm mật độ.
- YOLO+RP bám sát baseline $\Rightarrow$ Rich Prompt bù đắp ngữ nghĩa hiệu quả.

3.4. Phân tích MAE theo kích thước đối tượng



Nhận xét

- Xu hướng ngược lại so với mật độ: đối tượng nhỏ ($<500 \text{ px}^2$) có MAE cao nhất.
- Đối tượng lớn ($>6000 \text{ px}^2$): MAE thấp nhất.
- YOLO-World (không RP) chênh lệch lớn nhất ($\sim 4\text{--}5 \text{ MAE}$) ở nhóm đối tượng nhỏ.
- Rich Prompt thu hẹp khoảng cách đáng kể.

Ngày 3 tháng 5 năm 2026 29 / 40

3.4. So sánh định tính giữa VA-Count và Yolo-World (tt.)

VA-Count (GroundingDINO)

VA-COUNT: Zero-Shot Object Counting Visualization

Ảnh gốc



Overlay Image + Prediction



CLIP Score: 0.8386

Image ID:

716_004

GroundTruth Count: 180

Predicted Count: 176.87

Absolute Error: 3.13

Error Percentage: 1.74%

YOLO-World

VA-COUNT: Zero-Shot Object Counting Test Result



RESULT COMPARISON

Image ID: 716_004

Ground Truth Count: 180

Predicted Count: 137.30

Absolute Error: 42.70

Error Percentage: 23.72%

Hình 15: VA-Count (GroundingDINO) – ảnh 716: kết quả kém.

Hình 16: YOLO-World – ảnh 716: gặp khó khăn.

So sánh kết quả trên ảnh 716 (worst case)

Do năng lực nhận dạng ngữ nghĩa yếu hơn, YOLO-World chọn mẫu kém chính xác hơn, dẫn đến bản đồ mật độ phân tán và sai số đếm lớn hơn so với VA-Count gốc.

NHẬN XÉT

Khi đối tượng rõ ràng, YOLO-World cạnh tranh tốt. khi đối tượng có hình dạng hoặc kết cấu (texture) tương tự vật thể nền, việc thiếu cơ chế tương tác thị giác-ngôn ngữ tại thời điểm suy luận khiến YOLO-World chọn sai mẫu, dẫn đến bản đồ mật độ bị phân tán và sai số đếm tăng đáng kể. Đây chính là lý do Rich Prompt mang lại cải thiện lớn ($\Delta\text{MAE} = 1,12$) cho YOLO-World: mô tả ngữ nghĩa chi tiết từ LLM giúp bù đắp khả năng phân biệt mà YOLO-World thiếu.

3.5. Phân tích lỗi sai

Mật độ dày đặc

Đối tượng nhỏ, sát nhau $\Rightarrow$
density map suy giảm $\Rightarrow$
đếm thiếu.



Hình 17: Lỗi mật độ dày: GT=371,
Pred $\approx$ 251.

Phân mảnh

Vật thể cấu trúc chia tách
(cửa sổ nhiều ô) $\Rightarrow$ nhiều
local maxima $\Rightarrow$ **đếm thừa.**



Hình 18: Lỗi phân mảnh: GT=13,
Pred $\approx$ 27.

Sai số phương pháp

Mô hình dựa vào global
features thay vì condition theo
mẫu $\Rightarrow$ **training data bias.**

Khi mẫu không hợp lệ, mô
hình vẫn ước lượng nhưng sai
lớn (GT=371, Pred $\approx$ 251).

Mục lục

- 1 Tổng quan đề tài
- 2 Phương pháp thực hiện
- 3 Thực nghiệm và kết quả
- 4 Demo và đánh giá hệ thống
- 5 Kết luận và hướng phát triển

4.1. Cài đặt và chạy demo

Thành phần chính

- `demo_app_advanced.py`: ứng dụng Streamlit nâng cao.
- `demo_inference.py`: thư viện suy luận dùng chung.
- `demo_pipeline_advanced.py`: module pipeline đầy đủ.
- `demo_visualization.py`: các hàm vẽ overlay.

Mã nguồn

[GitHub Repository](#)

Video Demo: cập nhật trong `README.md` (mục *Demo & Outputs*).

Hướng dẫn cài đặt

```
cd code/source-code
python -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt

# Set Gemini API key
cp .env.example .env
# edit .env: GEMINI_API_KEY=...

# Run Streamlit demo
streamlit run demo_app_advanced.py
```


4.2. Giao diện và tương tác

Tùy chọn cấu hình

- Bộ trích xuất: GroundingDINO / YOLO-World.
- Bật/tắt Rich Prompt.
- Mặc định: **YOLO-World + Rich Prompt.**

Quy trình tương tác

- 1 Tải lên ảnh tự nhiên.
- 2 Nhập tên lớp tiếng Anh (ví dụ: oranges).
- 3 Nhận kết quả: tổng số đối tượng + density map overlay + bbox đường/âm.




Hình 19: Demo Streamlit: ảnh gốc + positive exemplars (trái), density map (giữa), overlay (phải). 346.jpg (strawberries): GT=11, Pred=11.26.


4.3. Đánh giá định tính

Kiểm thử trên ảnh khó từ FSC-147 và ảnh ngoài tập

- Cấu hình **YOLO-World + Rich Prompt** cho phản hồi nhanh ($\sim 2s$) và chấp nhận được trên CPU/GPU laptop.
- Khi tên lớp rõ ràng và đối tượng phân tách tốt, kết quả gần với ground truth.
- Trên các ảnh dày đặc hoặc tên lớp mơ hồ, hệ thống bộc lộ đúng các lỗi đã phân loại ở Mục 3.5 (mật độ dày đặc, phân mảnh, sai số phương pháp).



Hình 20: Kết quả đếm trên ảnh peas: density map tập trung đúng vị trí.



Hình 21: Trường hợp mật độ dày đặc (175 đối tượng): mẫu âm (đỏ) đánh dấu nền, mẫu dương (xanh lá) chọn đúng marker pen.

5.1. Kết luận

Về kiến trúc

VA-Count là thiết kế giàu thông tin học được, tách rõ giữa pha lấy mẫu (EEM) và pha sinh bản đồ mật độ (NSM). Nhánh dương/âm tạo điều kiện cho cơ chế học tương phản (contrastive), hữu hiệu cho zero-shot counting.

Về cải tiến

- **Rich Prompt:** hiệu quả lớn với YOLO-World (19,03 $\rightarrow$ 17,91, $\Delta = 1,12$), khiêm tốn với GDino ($\Delta = 0,19$) do bão hòa ngưỡng nghĩa.
- **YOLO-World:** loại bỏ bottleneck tốc độ (trích xuất: 25h $\rightarrow$ 4h; demo: 0,60s/ảnh).
- **YOLO-World + Rich Prompt:** cân bằng tốt nhất – MAE 17,91 với 2,4s/ảnh.
- **Phát hiện quan trọng:** bộ phát hiện càng yếu về ngưỡng nghĩa, Rich Prompt càng mang lại lợi ích lớn.

Về cài đặt

- Hàm tương phản dạng *margin-ReLU* (tương đương softmax, ổn định số học hơn).
- CLIP ViT-L/14 cho re-ranking; CLIP ViT-B/32 cho bộ phân loại nhị phân.
- Gemini 2.0 Flash (*gemini-2.0-flash-exp*) thay Gemini 2.5 Flash.

Hạn chế

- Chất lượng đếm bị giới hạn bởi Counter (MAE-based) $\Rightarrow$ 4 cấu hình cùng kiến trúc Counter, chỉ khác EEM.
- Mật độ dày đặc (>500 obj/Mpx) $\Rightarrow$ MAE vượt 50; đối tượng phân mảnh $\Rightarrow$ đếm thừa.
- Mô hình có xu hướng dựa vào đặc trưng toàn cục thay vì condition theo mẫu (training data bias).

◀ ◻ ▶ ◀ 📄 ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ 🔍 ↺

38 / 40

Tài liệu tham khảo

-  H. Zhu *et al.*, *Zero-shot object counting with good exemplars*, ECCV, 2024.
-  H. Zhu *et al.*, *Expanding zero-shot object counting with rich prompts*, arXiv:2505.15398, 2025.
-  T. Cheng *et al.*, *YOLO-World: Real-time open-vocabulary object detection*, CVPR, 2024.
-  S. Liu *et al.*, *Grounding DINO: Marrying DINO with grounded pre-training*, ECCV, 2024.
-  A. Radford *et al.*, *Learning transferable visual models from natural language supervision (CLIP)*, ICML, 2021.
-  V. Ranjan *et al.*, *Learning to count everything (FSC-147)*, CVPR, 2021.
-  Google DeepMind, *Gemini API documentation*, 2024–2026.
-  K. He *et al.*, *Masked autoencoders are scalable vision learners*, CVPR, 2022.

Cảm ơn!

Xin cảm ơn cô Dương Việt Hằng và các bạn!

Hỏi đáp – Demo